

# Explicabilité des modèles de classification de textes, application NLP – Approche BERT

**Sofiane AGOUNI KACI**

Modélisation des systèmes intelligents  
Master 2 vision et machine intelligente

2026


# Table of Contents

- 1 Contexte
- 2 Architecture du classifieur
- 3 Evaluation
- 4 Explicabilite
- 5 Limites et conclusion

## Contexte

# Probleme et objectif

- Comparer le fine-tuning complet de BERT et le linear probing.
- Expliquer les decisions du modele avec SHAP, LIME et les poids d'attention.




# Dataset

## Taille des splits

| Split | Total | Femme | Homme |
|-------|-------|-------|-------|
| Train | 852   | 492   | 360   |
| Val.  | 284   | 164   | 120   |
| Test  | 285   | 165   | 120   |

- Les labels sont extraits des noms de fichiers.
- Les distributions sont proches entre validation et test.
- Risque: biais possibles dans les données et dans le protocole de labellisation.



Distribution totale homme/femme


### Distribution des classes par split

Répartition des classes Femme et Homme dans les ensembles d'entraînement, validation et test.



Distribution des classes par split

# Pipeline global



## Architecture du classifieur

# Decoupage des documents


## Parametres de chunking

- 64 chunks par document pour la classe `homme`.
- 32 chunks par document pour la classe `femme`.

## Justification

Ce choix est utilise car il y a beaucoup plus de documents `femme` que de documents `homme`. Le nombre de chunks par document est ajuste pour limiter le desequilibre effectif pendant l'apprentissage.

# Architecture du reseau




# Entrainement 1 – fine-tuning complet de BERT


## Hyperparametres

Taille de batch = 32  
 Nombre d'epoques = 5  
 Optimiseur = AdamW

Batch d'evaluation = 32  
 Taux d'apprentissage =  $2e-5$



Courbes d'entrainement




# Entrainement 2 – linear probing

## Hyperparametres


Taille de batch = 32  
Nombre d'epoques = 5  
Optimiseur = AdamW

Batch d'evaluation = 32  
Taux d'apprentissage =  $2e-5$




# Evaluation

# Evaluation – linear probing



## Scores par classe


| Classe           | Precision | Recall | F1-score |
|------------------|-----------|--------|----------|
| femme            | 82.1%     | 80.6%  | 81.3%    |
| homme            | 74.0%     | 75.8%  | 74.9%    |
| Accuracy globale | 78.6%     |        |          |



# Explicabilite

## SHAP

## Principe de la methode SHAP




Source: image generee par IA, prompt engineering.

## Principe de la methode LIME




Source: image generee par IA, prompt engineering.

# Explications globales: SHAP




Termes soutenant les predictions homme




Termes soutenant les predictions femme

# Explications globales: LIME



Termes soutenant les predictions homme



Termes soutenant les predictions femme

LIME approxime localement le comportement du classifieur autour d'un exemple.


# Comparaison entre SHAP et LIME

- Les termes communs entre SHAP et LIME indiquent les indices lexicaux les plus stables pour chaque classe.
- On observe une convergence partielle entre les deux méthodes, ce qui renforce la confiance dans ces termes.
- Ces termes restent toutefois liés au dataset et ne doivent pas être interprétés comme des règles générales.


## Termes communs

| Classe | Termes communs                             |
|--------|--------------------------------------------|
| Homme  | <i>je, de, il, j</i>                       |
| Femme  | <i>l, elle, les, marie, suis, d, seule</i> |

# Explication locale: SHAP



# Explication locale: LIME




# Visualisation des scores d'attribution

## Scores d'attribution directement projetés sur le texte

travers l'herbe rouge du pays. la **machine**, à cent pas, charcutait le ciel de sa structure d'acier gris, le cernait de triangles inhumains. la combinaison de **saphir lazuli**, le mécanicien, s'agitait comme un gros **hanneton** cachou près du moteur. **saphir** était dans la combinaison. de loin, **wolf** le hêla et le **hanneton** se redressa et s'ébroua. **il** rejoignit **wolf** à **dix** mètres de l'appareil et ils terminèrent ensemble. vous venez le vérifier? demanda t **il**. **il** m a l air d'être temps, dit **wolf**. **il** regarda l'appareil. la case était remontée, et entre les quatre pieds râblés béait un puits profond. **il** contenait, rangés en bon ordre, les **éléments** destructeurs qui viendraient s'ajuster automatiquement à la suite les uns des autres, **au** fur et à **mesure** de leur usure. pourvu qu **il** n y ait pas de pépin, dit **wolf**. après **tout**, ça peut ne pas tenir. c'est calculé juste. si on a un seul pépin avec une **machine** pareille, grogna **saphir**, j'apprends le **brenouillou** et je ne parle plus que ça **tout** le reste de ma vie. je l

# Attention weights

Termes les plus importants par classe (Attention Weights)



## Limites et conclusion

# Limites

## Representation et donnees

- BERT est plus couteux a entrainer et a expliquer.
- Les labels et les textes peuvent contenir des biais.
- Les resultats dependent du chunking et de ce corpus.

## Explicabilite

- Les explications SHAP/LIME sont specifiques au modele.
- Les visualisations locales dependent fortement de l'exemple choisi.
- Les explications locales peuvent varier selon les exemples choisis.

# Conclusion

## Messages a retenir

- 1 BERT/CamemBERT permet de modeliser le contexte lexical des textes.
- 2 Fine-tuning complet et linear probing testent deux regimes d'apprentissage.
- 3 SHAP et LIME identifient les termes qui influencent les predictions.
- 4 Les explications locales et les attention weights rendent les decisions plus inspectables.
- 5 On explique ce classifieur sur ce dataset, pas le langage humain en general.

**Merci pour votre attention**

**Questions ?**