

Explicabilité des modèles de classification de textes, application NLP – Approche TF-IDF

Hamza OMARI

Modélisation des systèmes intelligents
Master 2 vision et machine intelligente

2026

Table of Contents


- 1 Contexte
- 2 Architecture du classifieur
- 3 Evaluation
- 4 Explicabilite
- 5 Perturbations
- 6 Limites et conclusion

Contexte

Probleme et objectif

- Construire un classifieur TF-IDF + MLP pour la prediction homme/femme.
- Expliquer les decisions du modele avec Integrated Gradients, LRP et les tests de perturbation.

Pipeline TF-IDF + MLP explicable




Dataset

Taille des splits

Split	Total	Femme	Homme
Train	852	492	360
Val.	284	164	120
Test	285	165	120

- Les labels sont extraits des noms de fichiers.
- Les distributions sont proches entre validation et test.
- Risque: biais possibles dans les données et dans le protocole de labellisation.



Distribution totale homme/femme


Distribution des classes par split

Répartition des classes Femme et Homme dans les ensembles d'entraînement, validation et test.




Distribution des classes par split

Pipeline global



Architecture du classifieur


Architecture 1




Courbes d'entrainement – architecture 1

Hyperparametres



BATCH_SIZE	=	8	EPOCHS	=	50
Optimizer	=	AdamW	LEARNING_RATE	=	1e-4
WEIGHT_DECAY	=	1e-4			



Architecture pour reduire l'overfitting



Nouvelles courbes d'entrainement



Evaluation


Resultats de classification

Metriques globales

- Accuracy test: **0.853**
- Macro F1: **0.850**
- Weighted F1: **0.853**

Classe	Precision	Recall	F1
Femme	0.882	0.861	0.871
Homme	0.815	0.842	0.828

Le coeur de l'étude n'est pas seulement la performance, mais l'explication de cette performance.



Explicabilite

1 Entrée et baseline

Entrée x

[je]	[suis]	[allée]	[au]	[travail]
------	--------	---------	------	-----------

Baseline x'

[PAD]	[PAD]	[PAD]	[PAD]	[PAD]
-------	-------	-------	-------	-------

La baseline est une entrée neutre (ex. : uniquement des tokens PAD).

2 Chemin d'interpolation

$x' + \alpha (x - x')$

$\alpha = 0$

[PAD]	[PAD]	[PAD]	[PAD]	[PAD]
-------	-------	-------	-------	-------

↓

$\alpha = 0,5$

[je]	[suis]	[allée]	[au]	[travail]
------	--------	---------	------	-----------

↓

$\alpha = 1$

[je]	[suis]	[allée]	[au]	[travail]
------	--------	---------	------	-----------

On interpole de la baseline x' ($\alpha = 0$) vers l'entrée x ($\alpha = 1$).

3 Gradients le long du chemin

$\alpha = 0$

Modèle F (classifieur)
 $\frac{\partial G}{\partial x_i}$

 $\rightarrow \frac{\partial F(x' + 0 \cdot (x - x'))}{\partial x_i}$

$\alpha = 0,5$

Modèle F (classifieur)
 $\frac{\partial G}{\partial x_i}$

 $\rightarrow \frac{\partial F(x' + 0,5(x - x'))}{\partial x_i}$

$\alpha = 1$

Modèle F (classifieur)
 $\frac{\partial G}{\partial x_i}$

 $\rightarrow \frac{\partial F(x' + 1 \cdot (x - x'))}{\partial x_i}$

4 Attribution des tokens

Entrée x

[je]	[suis]	[allée]	[au]	[travail]
------	--------	---------	------	-----------

Attribution $I_{G_i}(x)$

-0,05	0,07	0,72	-0,03	0,11
-------	------	------	-------	------

-0,5
0
0,5

Contribution négative Neutre Contribution positive

Token le plus influent : **allée**

Prediction : **Femme** (0,82)

A set of small navigation icons typically found in Beamer presentations, including symbols for back, forward, search, and other slide controls.

Principe de la methode LRP






image générée par IA, prompt engineering.

Explications globales: Integrated Gradients




Termes soutenant les predictions homme




Termes soutenant les predictions femme

Formulation volontaire: ces termes soutiennent le modele, ils ne definissent pas des groupes humains.

Explications globales: LRP



Termes soutenant les predictions homme



Termes soutenant les predictions femme

LRP propage la relevance a travers le reseau; BatchNorm/Dropout sont traites comme pass-through.

Convergence des attributions IG et LRP

Classe	Termes communs IG/LRP
Homme	fit, jules
Femme	marie, fanny, tante

L'intersection entre IG et LRP permet d'identifier les termes les plus stables pour chaque classe.

Les termes communs montrent que les deux méthodes convergent partiellement vers les mêmes indices lexicaux.

Visualisation des scores d'attribution

Les scores d'attribution sont visualisés directement sur le texte pour relier les termes aux décisions du modèle.

puis me permettre mais je ne me le permis pas . je le priai de s'asseoir et me glissai derrière mon burlingue où **brigitte** avait ordre de déposer chaque jour une rose rouge dans un vase col de cygne . je possède une usine de pâte à papier dans la région parisienne , dit il . puis il me fixa attentivement et désigna ma tête d'un ongle carré : vous êtes bagarreur ? je mis un instant à comprendre que j'avais oublié d'enlever complètement le sang qui caillait mes sourcils . non , dis je , pas tellement . mais l'autre l'était . excusez moi un instant . je sortis et me plantai devant **brigitte** qui tapait enfin un rapport pour une société de crédit . vous n'auriez pas pu me dire , **fis** je en montrant mon front . quoi ? oh , dit elle , vous avez du sang dans les sourcils . merci du ren saignement , dis je finement comme si j'étais un héros de carter brown . regardez dans l'annuaire de la région parisienne par professions si vous trouvez une usine **cloche** qui fait de la pâte à papier . **cloche** , c l o c h e . j'avais compris , dit elle un peu pincée . je montai dare dare jusqu'à ma s . de b . , me nettoyai et je redescendis comme si l'inférieur bigaillait encore à mes trousses . **brigitte** me fit un signe d'acquiescement et me désigna sur l'annuaire une ligne consacrée à l'usine **cloche** . téléphonez , dis je et demandez si m . **edmond** **cloche** est là . si il y est , raccrochez et venez m'apporter un dossier à signer . je rentrai dans le bureau où **edmond** **cloche** attendait patiemment . il ne fumait pas , ne se tortillait

Perturbations

Protocole de perturbation

Validation comportementale


- 1 Sélectionner des textes correctement classes.
- 2 Recuperer les top termes explicatifs.
- 3 Perturber les textes.
- 4 Relancer le modele.
- 5 Mesurer l'impact.

Modes testes


- **remove**: suppression des termes.
- **mask**: remplacement par [MASK].
- **swap**: remplacement par des termes de l'autre classe.

Mesures: baisse d'accuracy, baisse de confiance, nombre de predictions inversees.

Perturbations: accuracy et confiance



Accuracy avant/apres perturbation



Confidence drop

Resultats des perturbations

Methode	Mode	Acc. apres	Baisse acc.	Predictions inversees
IG	remove	0.97	0.03	3
IG	mask	0.97	0.03	3
IG	swap	0.90	0.10	10
LRP	remove	1.00	0.00	0
LRP	mask	1.00	0.00	0
LRP	swap	0.97	0.03	3
Intersection	remove	0.99	0.01	1
Intersection	mask	0.99	0.01	1
Intersection	swap	0.98	0.02	2

- Si la suppression ou modification des termes explicatifs reduit l'accuracy ou la confiance, alors ces termes sont comportementalement importants pour ce modele.

Limites et conclusion

Limites

Representation et donnees

- TF-IDF ignore l'ordre des mots et la syntaxe.
- Les labels et les textes peuvent contenir des biais.
- Les resultats dependent de ce corpus.

Explicabilite

- Les explications sont specifiques au modele.
- Les perturbations peuvent creer des textes peu naturels.
- LRP a travers BatchNorm/Dropout est approxime comme pass-through.

Aucune conclusion ne doit etre lue comme un marqueur universel du genre.

Conclusion

Messages a retenir

- 1 TF-IDF + MLP donne une baseline forte et interpretable.
- 2 Integrated Gradients et LRP identifient les termes qui influencent les predictions.
- 3 Les perturbations verifient si ces termes affectent reellement le comportement du modele.
- 4 On explique ce classifieur sur ce dataset, pas le langage humain en general.

Merci pour votre attention

Questions ?